analyse

February 11, 2025

1 Analyse pour BILL

```
[1]: import stats
  import compare_vcf as comp
  from read_vcf import parse_vcf_noerror
  import re
  import numpy as np
  import matplotlib.pyplot as plt
  from read_ORF import list_interval_with_dico
```

1.0.1 Sommaire:

- 1. Analyse descriptive de P90
 - 1) Récupération des données depuis vcf
 - 2) Analyse des fréquences alléliques et profondeurs
 - 3) Filtrage des sy selon la fréquence et la profondeur
 - 4) Distribution des types et tailles de sv
 - 5) Similarité entre échantillons
 - 6) Variants exclusifs à chaque groupes
 - 7) Variants exclusifs dans des ORFs
- 2. Analyse des échantillons au fils des itérations (au fil du temps)
 - 1) Échantillon 1 (froid)
 - 2) Échantillon 10 (chaud)


1.1 1. Analyse descriptive de P90


1.1.1 1.1 Récupération des données


- On prend les variants des vcf P90-x avec une liste pour chaque échantillon
- On créé un ensemble avec tous les variants des P90
- On créé un ensemble avec tous les variants du groupe froids : P90-1 à P90-5
- On créé un ensemble avec tous les variants du groupe chauds : P90-6 à P90-10

1.1.2 1.2 Fréquences alléliques et profondeurs dans l'ensemble des variants

```
[3]: af = [v["af"] for v in all variant]
     depth = [max(v["depth"]) for v in all_variant]
     fig, ax = plt.subplots()
     ax.hist(af, bins=50)
     ax.set_xlabel('Fréquence allélique')
     ax.set_title("Distribution des fréquences alléliques")
     fig.tight_layout()
     plt.show()
     fig, ax = plt.subplots()
     ax.hist(depth, bins=50)
     ax.set_xlabel('Profondeur maximal')
     ax.set_title("Distribution des profondeur d'aligment")
     fig.tight_layout()
     plt.show()
     # Fixing random state for reproducibility
     np.random.seed(19680801)
     x = np.random.rand(20)
     y = 1e7 * np.random.rand(20)
     fig, ax = plt.subplots()
     plt.plot(af, depth, 'o')
     ax.set_xlabel('Fréquence allélique')
     ax.set_ylabel('Profondeur maximal')
     plt.show()
```







1.1.3 Filtrage des variants basés sur une profondeur et une fréquence allélique minimum

• Pour la profondeur on considère la valeur max des différentes profondeurs fournis pour un même variant

```
[4]: min_depth = 500
min_freq = 0.2
data = [[v for v in d if v['af'] > min_freq and max(v['depth'])> min_depth] for
d in data]
```


1.1.4 1.4 Distribution des type et des tailles de variants


- Les variants sont regroupé par similarité (<thresold> = proportion minimum de similarité), ceci pour l'ensemble total, l'ensemble chaud et l'ensemble froid
- $\bullet\,$ La similarité entre 2 variants structurels est calculé d'après le nombre de base partagés (identiques à la même position) entre les 2
- Ainsi plusieurs occurences "similaires" d'un même variant ne sont compté qu'une fois


1.4.1 Distribution des types

```
[5]: thresold = 1
     all_variant_grouped = comp.merge_samples(data, sim_thresold=thresold)
     cold_group_grouped = comp.merge_samples(data[0:5], sim_thresold=thresold)
     heat_group_grouped = comp.merge_samples(data[5:10], sim_thresold=thresold)
     counts_all = stats.count_types([grp[0][1]["svtype"] for grp in_
      →all_variant_grouped])
     counts_cold = stats.count_types([grp[0][1]["svtype"] for grp in_
      →cold_group_grouped])
     counts_heat = stats.count_types([grp[0][1]["svtype"] for grp in_
      →heat_group_grouped])
     grouped_labels = list( set(counts_cold.keys()).union(counts_heat.keys()) )
     grouped_counts = {
         "Froid": [counts_cold[k] if k in counts_cold else 0 for k in_
      ⇒grouped_labels],
         "Chaud": [counts_heat[k] if k in counts_heat else 0 for k in_
      ⇔grouped_labels],
     }
     stats.plot_count_by_type(counts_all)
     stats.plot_grouped_count_by_type(grouped_counts, grouped_labels)
```


Nombre de variants par type









1.4.2 Distribution de tailles par type, avec et sans outliers








1.1.5 1.5 Similarité par paire d'échantillon P90

• La case P90-4 / P90-5 par exemple affiche la proportion de variants partagé (similaires) entre ces deux échantillons

```
[7]: sims = comp.pairwise_similarity(list(range(0, 10)), all_variant_grouped)
     comp.variant_heatmap(sims, [f"P90-{i}" for i in range(1, 11)])
```



1.1.6 1.6 Extraction des variants présent uniquement dans le chaud ou le froid

• On compte aussi le nombre d'occurence de chaque variant au travers des échantillons

```
[8]: only_cold = []
  only_heat = []

for g in all_variant_grouped:
    present_in = 0
    counts = len(g)
    for v in g:
        if v[0] <= 4: # Groupe froid
            present_in = present_in | 1
        elif v[0] <= 9: # Groupe chaud
            present_in = present_in | 2

if present_in == 1: # Groupe froid
        g[0][1]["n_found"] = counts
        only_cold.append(g[0][1])</pre>
```

```
elif present_in == 2: # Groupd chaud
g[0][1]["n_found"] = counts
only_heat.append(g[0][1])
```

Variants trouvés uniquement dans le groupe froid

```
[9]: for c in only_cold: print(c)
```

```
{'pos': 37879, 'id': 'Sniffles2.INS.70S0', 'svtype': 'INS', 'svlen': 26, 'end':
37879, 'af': 0.671, 'depth': [4318.0, 4144.0, 4172.0, 4157.0, 4353.0], 'alt':
[TGTGTGTGTGTGTGTGTGTGTGTG], 'n_found': 1}
{'pos': 37879, 'id': 'Sniffles2.INS.3BS0', 'svtype': 'INS', 'svlen': 28, 'end':
37879, 'af': 0.681, 'depth': [4881.0, 4668.0, 4683.0, 4688.0, 4959.0], 'alt':
[TGTGTGTGTGTGTGTGTGTGTGTG], 'n found': 1}
{'pos': 83046, 'id': 'Sniffles2.INS.FFS0', 'svtype': 'INS', 'svlen': 39, 'end':
83046, 'af': 0.234, 'depth': [4148.0, 4147.0, 4124.0, 4094.0, 4109.0], 'alt':
[ACCAGAAGCAGCCGAAGCAGCCGAAGC], 'n_found': 1}
{'pos': 83076, 'id': 'Sniffles2.INS.EDS0', 'svtype': 'INS', 'svlen': 48, 'end':
83076, 'af': 0.746, 'depth': [3694.0, 3725.0, 3687.0, 3639.0, 3637.0], 'alt':
[CGAAGCAGCCGAAGCAGCCGAAGCAGCCGAAGCAGACCAAACCCGACG], 'n_found': 1}
{'pos': 270829, 'id': 'Sniffles2.INS.33BS0', 'svtype': 'INS', 'svlen': 19,
'end': 270829, 'af': 0.8, 'depth': [4962.0, 4868.0, 5040.0, 5113.0, 5105.0],
'alt': [ACAGAGACACAAAACAGAC], 'n_found': 1}
{'pos': 272444, 'id': 'Sniffles2.INS.34CSO', 'svtype': 'INS', 'svlen': 715,
'end': 272444, 'af': 1.0, 'depth': [5130.0, 1.0, 1.0, 1.0, 0.0], 'alt': [TTGAACA
\tt GTGGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGT
GGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGG
ACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGGACAC\\
GGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGGACACGG
TGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGGACCGGTGGAAGGTTGAACATGGTGGACACGGTG
{\tt AGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGACCTTGCCACCCTACTTTTTCTCTA}
GAGCTTAACCCTAATT], 'n_found': 1}
{'pos': 272444, 'id': 'Sniffles2.INS.34DS0', 'svtype': 'INS', 'svlen': 8077,
'end': 272444, 'af': 1.0, 'depth': [5130.0, 1.0, 1.0, 1.0, 0.0], 'alt': [<INS>],
'n found': 1}
{'pos': 272444, 'id': 'Sniffles2.INS.333S0', 'svtype': 'INS', 'svlen': 235,
'end': 272444, 'af': 1.0, 'depth': [4144.0, 1.0, 1.0, 1.0, 0.0], 'alt': [TTGAACA
\tt GTGGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGT
GGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGACCTTGCCACCCTACTTTTCTCTAGAGCTTAACCCTAAT
T], 'n found': 1}
{'pos': 272491, 'id': 'Sniffles2.INS.349S0', 'svtype': 'INS', 'svlen': 12,
'end': 272491, 'af': 1.0, 'depth': [5130.0, 1.0, 1.0, 1.0, 0.0], 'alt':
```

```
[CTCTCTCTCTCT], 'n_found': 1} {'pos': 272491, 'id': 'Sniffles2.INS.331S0', 'svtype': 'INS', 'svlen': 13, 'end': 272491, 'af': 1.0, 'depth': [4144.0, 1.0, 1.0, 1.0, 0.0], 'alt': [AGTCCCTCTCA], 'n_found': 1}
```

Variants trouvés uniquement dans le groupe chaud

```
[10]: for h in only_heat:
    print(h)
```

```
{'pos': 9457, 'id': 'Sniffles2.DEL.1D5S0', 'svtype': 'DEL', 'svlen': -17, 'end':
9474, 'af': 0.594, 'depth': [1572.0, 1551.0, 1499.0, 1489.0, 1399.0], 'n found':
{'pos': 11384, 'id': 'Sniffles2.DEL.26BS0', 'svtype': 'DEL', 'svlen': -33,
'end': 11417, 'af': 1.0, 'depth': [3304.0, 3337.0, 3329.0, 3400.0, 3455.0],
'n found': 5}
{'pos': 15501, 'id': 'Sniffles2.INS.35S0', 'svtype': 'INS', 'svlen': 12, 'end':
15501, 'af': 1.0, 'depth': [6742.0, 6831.0, 6910.0, 6939.0, 7022.0], 'alt':
[TCATCATCATCA], 'n_found': 1}
{'pos': 16096, 'id': 'Sniffles2.DEL.1E5S0', 'svtype': 'DEL', 'svlen': -12,
'end': 16108, 'af': 0.616, 'depth': [1356.0, 1431.0, 1473.0, 1482.0, 1536.0],
'n found': 1}
{'pos': 16098, 'id': 'Sniffles2.DEL.1E6S0', 'svtype': 'DEL', 'svlen': -20,
'end': 16118, 'af': 0.216, 'depth': [1356.0, 1431.0, 1473.0, 1482.0, 1536.0],
'n found': 1}
{'pos': 21083, 'id': 'Sniffles2.DEL.1F3S0', 'svtype': 'DEL', 'svlen': -10,
'end': 21093, 'af': 0.383, 'depth': [1324.0, 1172.0, 1174.0, 1166.0, 1178.0],
'n found': 1}
{'pos': 32540, 'id': 'Sniffles2.DEL.27FS0', 'svtype': 'DEL', 'svlen': -17,
'end': 32557, 'af': 1.0, 'depth': [1861.0, 1834.0, 1827.0, 1839.0, 1891.0],
'n found': 3}
{'pos': 47346, 'id': 'Sniffles2.DEL.2D2S0', 'svtype': 'DEL', 'svlen': -1850,
'end': 49196, 'af': 0.49, 'depth': [2047.0, 2004.0, 1989.0, 2004.0, 2034.0],
'n_found': 1}
{'pos': 60281, 'id': 'Sniffles2.DEL.29CS0', 'svtype': 'DEL', 'svlen': -25,
'end': 60306, 'af': 1.0, 'depth': [1735.0, 1749.0, 1761.0, 1756.0, 1798.0],
'n found': 4}
{'pos': 83046, 'id': 'Sniffles2.INS.11FS0', 'svtype': 'INS', 'svlen': 39, 'end':
83046, 'af': 0.225, 'depth': [2269.0, 2263.0, 2249.0, 2224.0, 2214.0], 'alt':
[<INS>], 'n_found': 1}
{'pos': 83046, 'id': 'Sniffles2.INS.9ES0', 'svtype': 'INS', 'svlen': 39, 'end':
83046, 'af': 0.225, 'depth': [928.0, 940.0, 925.0, 920.0, 942.0], 'alt':
[ACCAGAGCAGCCGAAGCAGCCGGAGACGA], 'n_found': 1}
{'pos': 133271, 'id': 'Sniffles2.DEL.302S0', 'svtype': 'DEL', 'svlen': -12,
'end': 133283, 'af': 0.857, 'depth': [1765.0, 1805.0, 1775.0, 1775.0, 1799.0],
'n found': 3}
{'pos': 143509, 'id': 'Sniffles2.DEL.318S0', 'svtype': 'DEL', 'svlen': -24,
'end': 143533, 'af': 0.905, 'depth': [1772.0, 1807.0, 1805.0, 1819.0, 1875.0],
'n_found': 3}
```

```
{'pos': 155446, 'id': 'Sniffles2.DEL.32ES0', 'svtype': 'DEL', 'svlen': -33,
'end': 155479, 'af': 0.995, 'depth': [1717.0, 1769.0, 1786.0, 1777.0, 1773.0],
'n found': 4}
{'pos': 177568, 'id': 'Sniffles2.DEL.3C9S0', 'svtype': 'DEL', 'svlen': -82,
'end': 177650, 'af': 0.28, 'depth': [899.0, 857.0, 852.0, 853.0, 873.0],
'n found': 1}
{'pos': 177570, 'id': 'Sniffles2.DEL.37DS0', 'svtype': 'DEL', 'svlen': -80,
'end': 177650, 'af': 0.279, 'depth': [1893.0, 1858.0, 1859.0, 1852.0, 1863.0],
'n_found': 1}
{'pos': 231446, 'id': 'Sniffles2.INS.1FDS0', 'svtype': 'INS', 'svlen': 12,
'end': 231446, 'af': 1.0, 'depth': [1861.0, 1841.0, 1828.0, 1817.0, 1833.0],
'alt': [ACCTACCTGGTC], 'n_found': 1}
{'pos': 231446, 'id': 'Sniffles2.INS.294S0', 'svtype': 'INS', 'svlen': 12,
'end': 231446, 'af': 1.0, 'depth': [2286.0, 2270.0, 2275.0, 2231.0, 2250.0],
'alt': [CCTTACCTGGTC], 'n_found': 1}
{'pos': 254131, 'id': 'Sniffles2.DEL.3FASO', 'svtype': 'DEL', 'svlen': -18,
'end': 254149, 'af': 1.0, 'depth': [1834.0, 1799.0, 1787.0, 1797.0, 1800.0],
'n found': 4}
{'pos': 272446, 'id': 'Sniffles2.INS.2A2SO', 'svtype': 'INS', 'svlen': 287,
'end': 272446, 'af': 1.0, 'depth': [2152.0, 1.0, 1.0, 1.0, 0.0], 'alt': [TTGAACA
TGGTGGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATG
GGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGGACACGGTGGAAGGTTGAACATGGTGG
ACGGTGGAAGGA], 'n_found': 1}
{'pos': 272446, 'id': 'Sniffles2.INS.2A3SO', 'svtype': 'INS', 'svlen': 10394,
'end': 272446, 'af': 1.0, 'depth': [2152.0, 1.0, 1.0, 1.0, 0.0], 'alt': [<INS>],
'n_found': 1}
{'pos': 272448, 'id': 'Sniffles2.INS.2A4S0', 'svtype': 'INS', 'svlen': 23059,
'end': 272448, 'af': 1.0, 'depth': [2152.0, 1.0, 1.0, 1.0, 0.0], 'alt': [<INS>],
'n_found': 1}
```

1.1.7 Variants exclusifs à chaque groupes, se trouvant dans une ORF

```
print("Chauds dans les ORFs : ")
for h in only_heat:
    for orf in orfs:
        found = False
        for inter in orf["location"]:
            found = found or (min(h["end"], int(inter[1])) - max(h["pos"],
 \hookrightarrowint(inter[0])) > 0)
        if found:
            print(" ORF : ", orf)
            print(" Mutation : ", h)
            print()
Froids dans les ORFs :
Chauds dans les ORFs :
ORF: {'locus tag': 'CyHV3 ORF5 1', 'protein id': 'YP 001096044.1',
'location': [['8606', '9949']], 'direct': True, 'complement': False, 'join':
False}
Mutation: {'pos': 9457, 'id': 'Sniffles2.DEL.1D5S0', 'svtype': 'DEL',
'svlen': -17, 'end': 9474, 'af': 0.594, 'depth': [1572.0, 1551.0, 1499.0,
1489.0, 1399.0], 'n_found': 1}
ORF: {'locus_tag': 'CyHV3_ORF25', 'protein_id': 'YP_001096064.1', 'location':
[['45570', '47375']], 'direct': True, 'complement': False, 'join': False}
Mutation: {'pos': 47346, 'id': 'Sniffles2.DEL.2D2S0', 'svtype': 'DEL',
'svlen': -1850, 'end': 49196, 'af': 0.49, 'depth': [2047.0, 2004.0, 1989.0,
2004.0, 2034.0], 'n_found': 1}
ORF : {'locus_tag': 'CyHV3_ORF26', 'protein_id': 'YP_005352783.1', 'location':
[['47474', '47644']], 'direct': True, 'complement': False, 'join': False}
Mutation: {'pos': 47346, 'id': 'Sniffles2.DEL.2D2S0', 'svtype': 'DEL',
'svlen': -1850, 'end': 49196, 'af': 0.49, 'depth': [2047.0, 2004.0, 1989.0,
2004.0, 2034.0], 'n_found': 1}
ORF: {'locus_tag': 'CyHV3_ORF27', 'protein_id': 'YP_005352784.1', 'location':
[['48534', '48740']], 'direct': True, 'complement': False, 'join': False}
Mutation: {'pos': 47346, 'id': 'Sniffles2.DEL.2D2S0', 'svtype': 'DEL',
'svlen': -1850, 'end': 49196, 'af': 0.49, 'depth': [2047.0, 2004.0, 1989.0,
2004.0, 2034.0], 'n_found': 1}
ORF : {'locus_tag': 'CyHV3_ORF40', 'protein_id': 'YP_005352786.1', 'location':
[['60044', '60598']], 'direct': False, 'complement': True, 'join': False}
Mutation: {'pos': 60281, 'id': 'Sniffles2.DEL.29CS0', 'svtype': 'DEL',
'svlen': -25, 'end': 60306, 'af': 1.0, 'depth': [1735.0, 1749.0, 1761.0, 1756.0,
1798.0], 'n_found': 4}
ORF : {'locus_tag': 'CyHV3_ORF69', 'protein_id': 'YP_001096104.1', 'location':
[['132865', '134445']], 'direct': False, 'complement': True, 'join': False}
```

```
Mutation: {'pos': 133271, 'id': 'Sniffles2.DEL.302S0', 'svtype': 'DEL',
'svlen': -12, 'end': 133283, 'af': 0.857, 'depth': [1765.0, 1805.0, 1775.0,
1775.0, 1799.0], 'n_found': 3}
ORF: {'locus tag': 'CyHV3 ORF78', 'protein id': 'YP 001096113.1', 'location':
[['142353', '144593']], 'direct': True, 'complement': False, 'join': False}
Mutation: {'pos': 143509, 'id': 'Sniffles2.DEL.318S0', 'svtype': 'DEL',
'svlen': -24, 'end': 143533, 'af': 0.905, 'depth': [1772.0, 1807.0, 1805.0,
1819.0, 1875.0], 'n found': 3}
ORF : {'locus_tag': 'CyHV3_ORF84', 'protein_id': 'YP_001096119.1', 'location':
[['153583', '155916']], 'direct': False, 'complement': True, 'join': False}
Mutation: {'pos': 155446, 'id': 'Sniffles2.DEL.32ES0', 'svtype': 'DEL',
'svlen': -33, 'end': 155479, 'af': 0.995, 'depth': [1717.0, 1769.0, 1786.0,
1777.0, 1773.0], 'n_found': 4}
ORF : {'locus_tag': 'CyHV3_ORF148', 'protein_id': 'YP_001096183.1',
'location': [['253956', '255779']], 'direct': False, 'complement': True, 'join':
False}
Mutation: {'pos': 254131, 'id': 'Sniffles2.DEL.3FAS0', 'svtype': 'DEL',
'svlen': -18, 'end': 254149, 'af': 1.0, 'depth': [1834.0, 1799.0, 1787.0,
1797.0, 1800.0], 'n_found': 4}
```


1.2 2. Comparaison entre les itération d'un même échantillon (au fil du temps)


```
[12]: min_depth_it = 150
      min_freq_it = 0.05
      def plots_by_iteration(data_it, sample):
          labels it = [f"P{it}-{sample}" for it in iterations]
          values_it = [len(d) for d in data_it]
          # Barplot
          fig, ax = plt.subplots()
          ax.bar(labels_it, values_it)
          ax.set_title(f'Nombre de variants dans chaque itération de l\'échantillon⊔

√{sample}')
          ax.set_ylabel('Nombre de variants')
          plt.show()
          # Heatmap
          grouped_data_it = comp.merge_samples(data_it, sim_thresold=1)
          sims it = comp.pairwise similarity(list(range(0, 5)), grouped data it)
          comp.variant_heatmap(sims_it, [f"P{sample}-{i+1}" for i, sample in_u
       ⇔enumerate([15, 30, 50, 65, 90])])
```

1.2.1 2.1 Analyse de l'échantillon 1 (froid)

Nombre de variants dans chaque itération de l'échantillon 1





1.2.2 2.1 Analyse de l'échantillon 10 (chaud)

